GLOBAL TERRORISM DATABASE

DATA SLAYER:

- VINCENZO PIO FALSAPERLA
- FLAVIO MICCICHÉ
- SANTO LO BIANCO

GTD, SOLO UN DATASET?

Il Global Terrorism Database (GTD) è un dataset contenente oltre 180.000 attacchi terroristici avvenuti in tutto il mondo dal 1970 al 2016 (eccetto il 1993). Ma è soltanto un insieme di dati fine a se stesso?

Regione con più attacchi?

Tipologia di attacco prediletto dai gruppi terroristici?

Gli attacchi sono diminuiti nel tempo?

Luogo
(region, country, latitude, longitude);

Tempo
(year, month, day, weekday);

Gruppo terroristico
(gname);

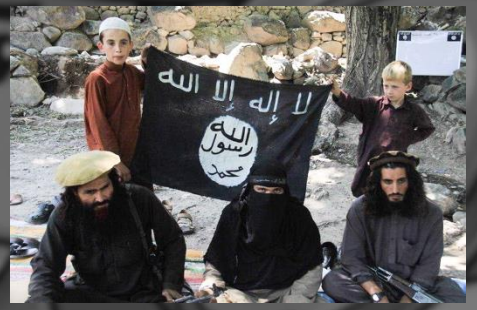

Modalità operative
(attacktype, weaptype);

Bersaglio
(targtype);

Letalità
(nwound, nkill).

COME SI DESCRIVE UN ATTACCO TERRORISTICO ATTRAVERSO I DATI?

MA CHE COS'È IL DATA UNDERSTANDING?

Una buona comprensione dei dati è fondamentale per analizzare il nostro Dataset, e tale processo si può suddividere in tre parti:

- Caricamento e Ispezione del Dataset;
- Stesura di un opportuno Dizionario dei Dati;
- Definizione degli obiettivi.

In particolare, per quest'ultima si propone l'utilizzo del modello delle 5 Ws + H sul Problem Solving, facendoci porre domande come:

- Quali sono i continenti o i paesi che subiscono più/meno attacchi terrostici? (Where?)
- Quanto sono letali i vari gruppi terroristici e quante vittime hanno causato? (How?/Who?)

INFERENZA STATISTICA

Con l'inferenza statistica (deduzione basata su popolazione vs campione ristretto), possiamo essere in grado di rispondere a domande generali senza la quale non saremmo in grado di rispondere, utilizzando tecniche come:

- campionamento;
- media, deviazione standard e standard error;
- intervalli di confidenza;
- test d'ipotesi e p-value.

3 DOMANDE INFERENZIALI

Media uccisioni in Middle East & North Africa

La media di 'nkill' nella regione più colpita è uguale a quella della popolazione?

Intervallo di confidenza per la media di vittime per attacco

Qual è il numero medio di vittime per attacco nkill sul campione e qual è l'intervallo di confidenza al 95% per questa media?

Confronto tra due campioni

Il numero medio di vittime per attacco è diverso tra il periodo prima del 2010 e il periodo 2010–2016?

3 RISPOSTE INFERENZIALI

Media uccisioni in Middle East & North Africa

Risulta più alta: abbiamo una media del 0.82 contro una media del 0.69

Intervallo di confidenza per la media di vittime per attacco

Numero medio di 0.69 (corrisponde!) e intervallo tra 0.68 e 0.72, con distribuzione fortemente asimmetrica tra maggioranza e minoranza attacchi

Confronto tra due campioni

Più alto nel periodo 2010-2016 che nel periodo 1970-2009: fatto degno di nota!

IL TERRORISMO ERA O È DIVENTATO UN'EMERGENZA?

I dati parlano chiaro: negli ultimi anni gli attacchi terroristici stanno diventando un'emergenza!
Dal 2005 si osserva un trend in crescita, probabilmente legato a profondi cambiamenti politici e socio-economici.

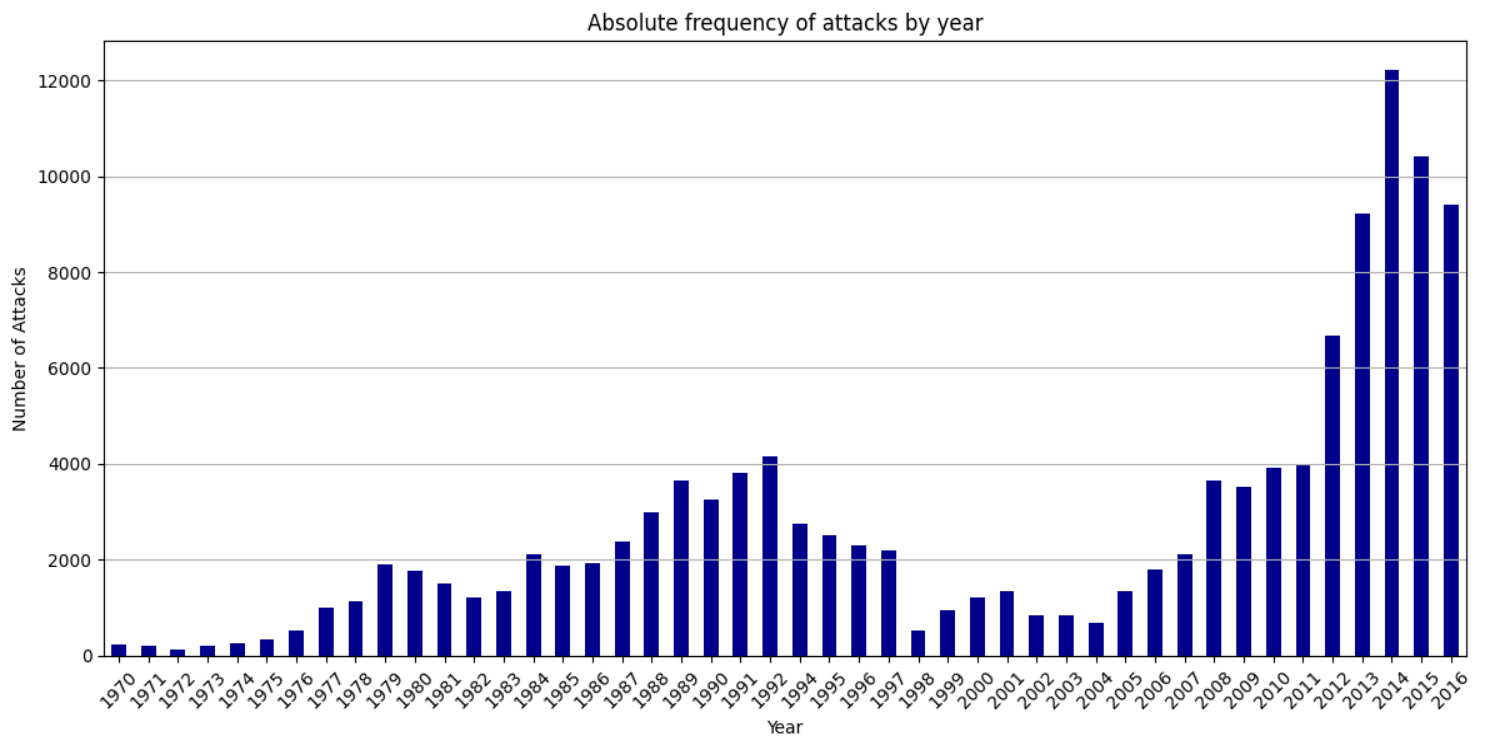

EMERGENZA GLOBALE O PROBLEMA DI POCHI PAESI?

Country	Absolute Frequency	Relative Frequency
Iraq	13880	0.113437
Pakistan	11200	0.091534
India	8162	0.066705
Afghanistan	8128	0.066427
Colombia	6123	0.050041
Philippines	4671	0.038175
Peru	4331	0.035396
Turkey	3295	0.026929
Thailand	3200	0.026153
United Kingdom	3117	0.025474
Brunei	1	0.000008
People's Republic of the Congo	1	0.000008
Wallis and Futuna	1	0.000008
New Hebrides	1	0.000008
St. Kitts and Nevis	1	0.000008
Dominica	1	0.000008
Vatican City	1	0.000008
North Korea	1	0.000008
Vanuatu	1	0.000008
Barbados	2	0.000016

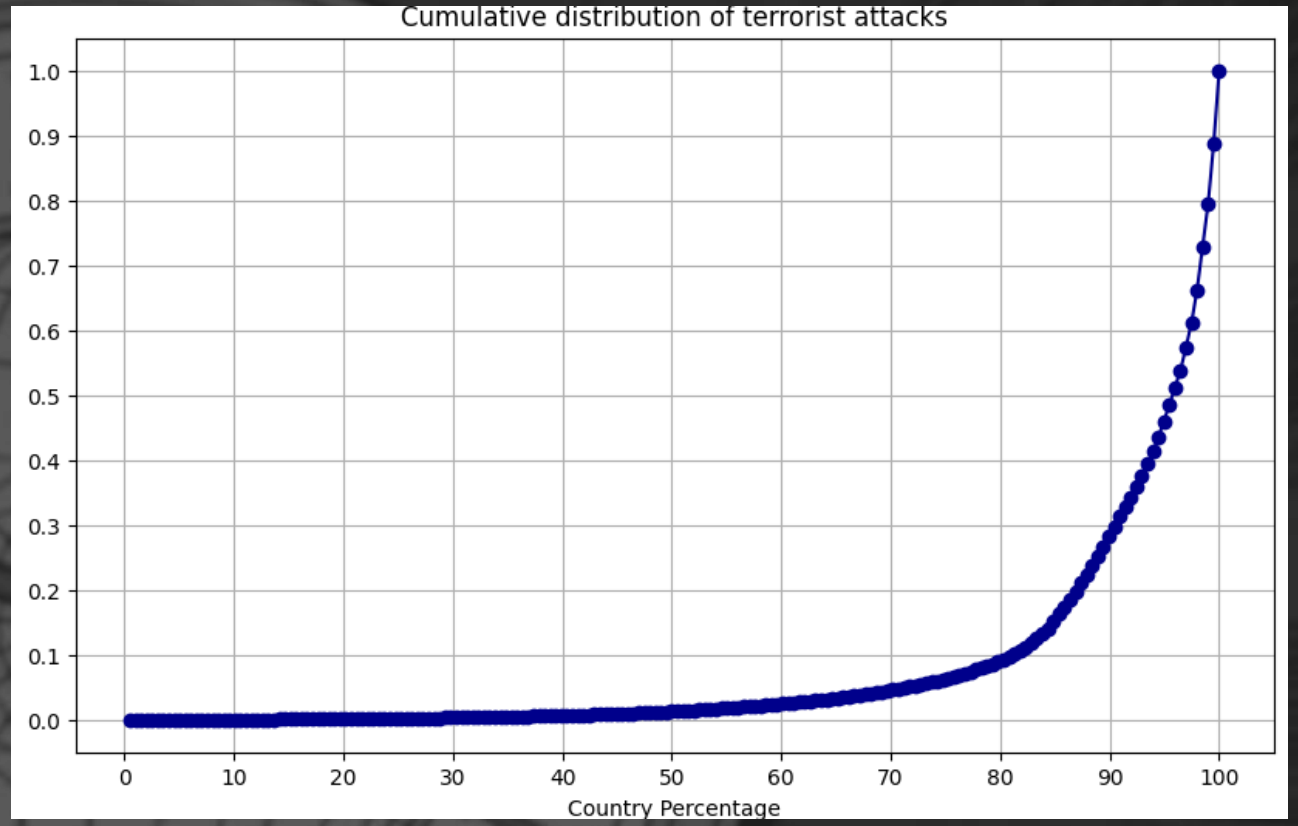

I dati mostrano che non è un'emergenza globale uniforme ma un problema fortemente concentrato. La quasi totalità degli attacchi colpisce una piccolissima percentuale di paesi, mentre in molti paesi l'incidenza del fenomeno è trascurabile o prossima allo zero.

MONDO DIVISO IN 4: EVOLUZIONI TEMPORALI E GEOGRAFICHE

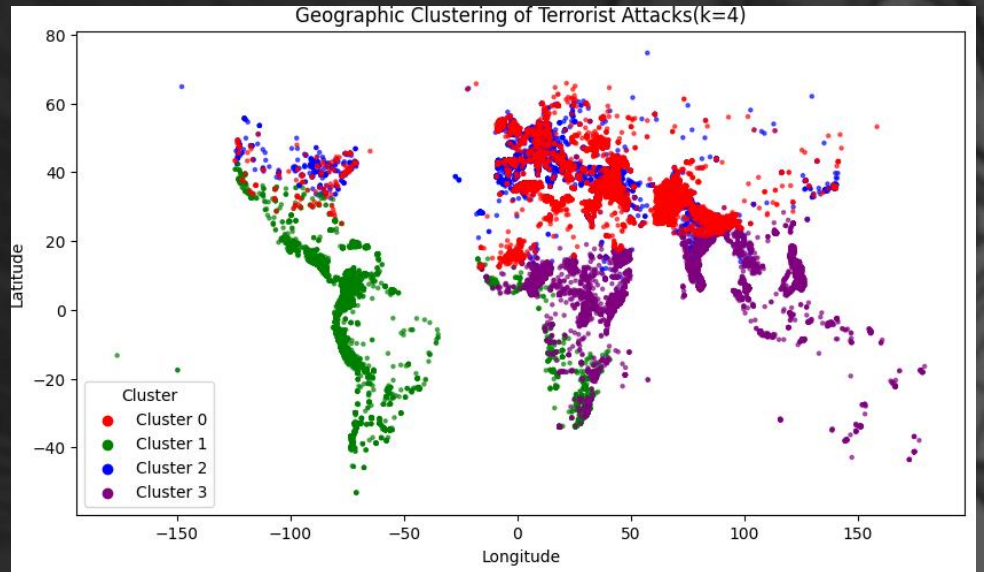

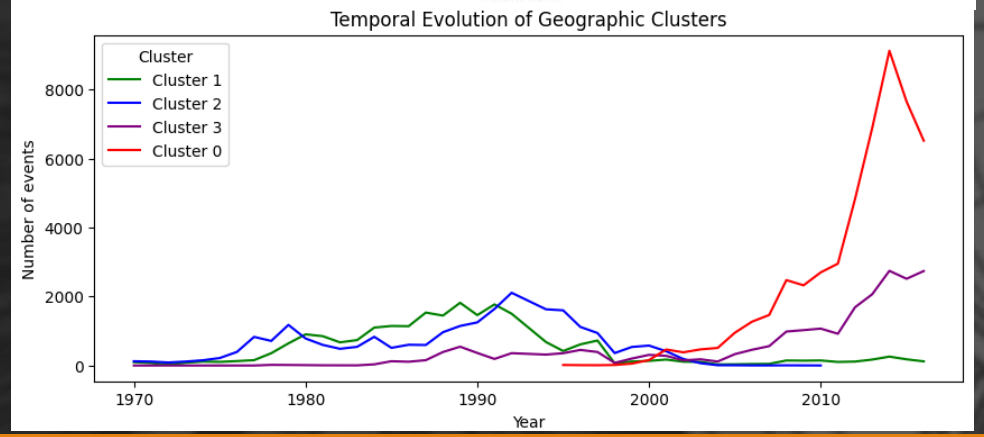

Oggi gli attacchi terroristici sono concentrati in Medio Oriente, Nord Africa e Asia Meridionale, con un trend in ascesa dalla metà degli anni ’90, che copre la maggior parte degli eventi presenti nel dataset.

Dalla fine della Guerra Fredda, il fenomeno si è progressivamente spostato verso nuove aree geografiche.

L’attentato alle Torri Gemelle ha segnato l’inizio di una nuova era, con il terrorismo incentrato su Medio Oriente e Asia Meridionale.

BERSAGLI NEI CONTINENTI

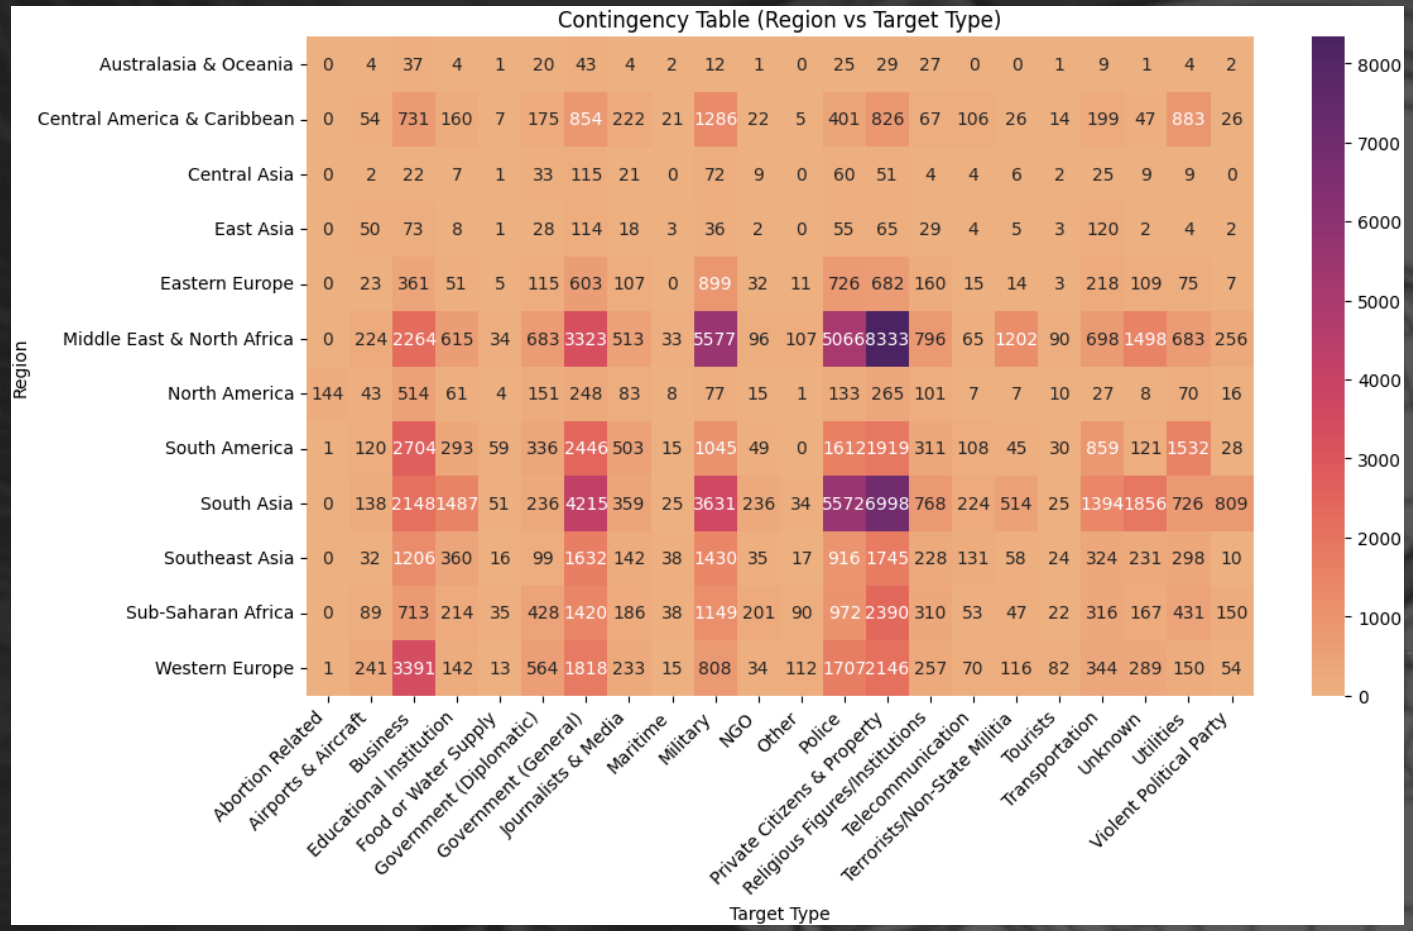

I bersagli principali, dove è concentrato il terrorismo sono:

- cittadini privati;
- polizia;
- militari.

I civili rappresentano il target più colpito, a conferma della massimizzazione dell'impatto psicologico sulla popolazione. Infine, in Europa Occidentale e Nord America, prevalgono attacchi contro attività commerciali (BUSINESS), segno di una strategia orientata a colpire l'economia.

CHI E' STATO? TALIBAN, PER IL 14% DELLE VITTIME GLOBALI

Il Taliban ha causato oltre 5.500 vittime, I gruppi successivi (Shining Path, ISIL, PKK, FARC...) si attestano tra 1.000 e 2.000 vittime, con frequenze relative tra il 2% e il 5%.

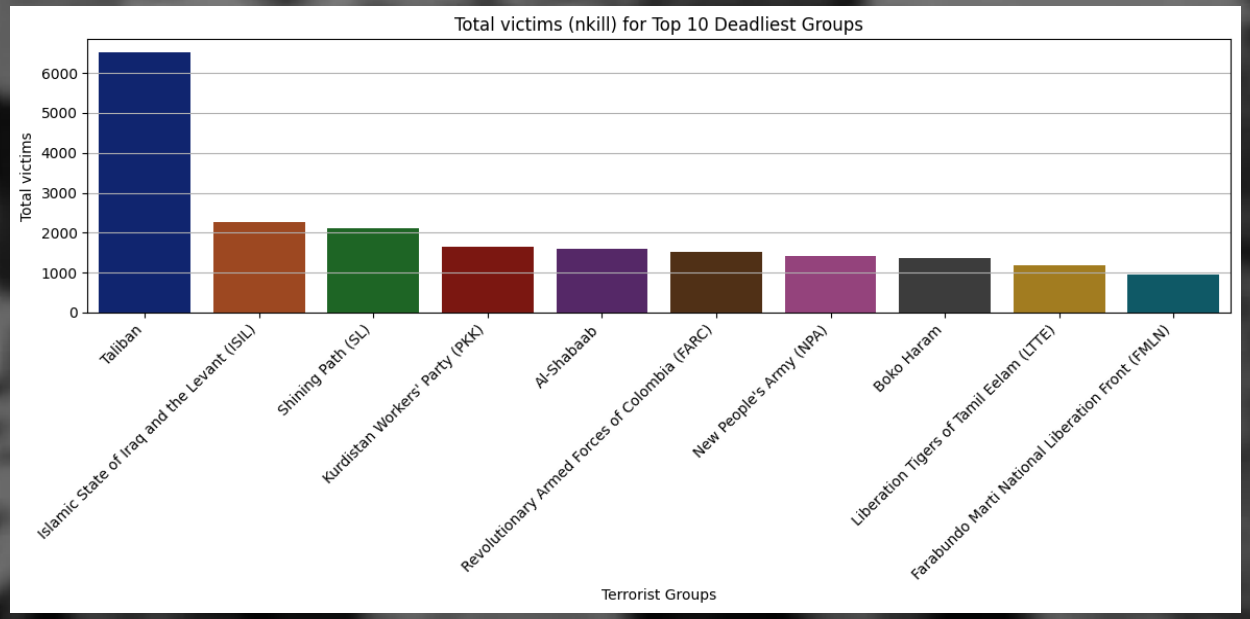

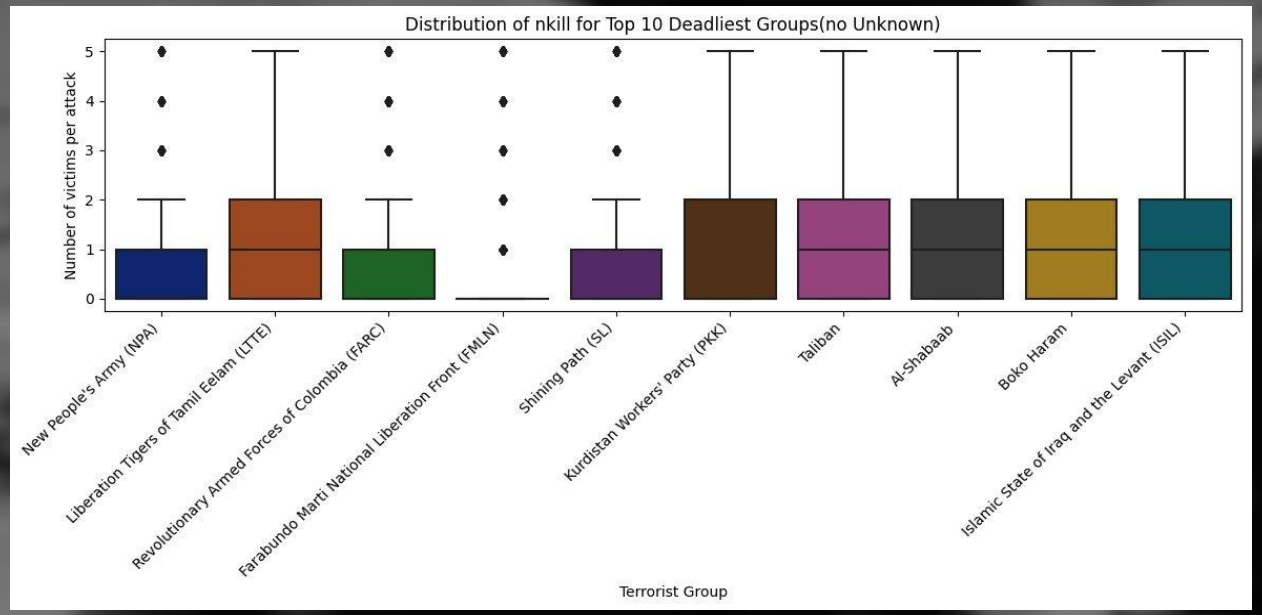

Dalla distribuzione dei relativi boxplot: distribuzione delle mediane schiacciata verso il basso
-> pochi attacchi con molte vittime
e molti attacchi con poche vittime.

50% WE WILL FIND YOU!

Ma quanti unknown! Prediciamoli!

Target: gname (top10).
Predittori: year, region_txt, attacktype1_txt, targtype1_txt, weaptype1_txt.

Strumenti: Preprocessing numerico e categorico, Suddivisione train/test set, Grid Search per C, Pipeline

Tutti I modelli hanno accuratezza alta ma:

- LR, costo computazionale maggiore;
- Gaussian NB, meno accurato causa dell'assunzione di indipendenza condizionale

Gruppi terroristici con più attacchi:

	gname	freq_abs	freq_rel
0	Unknown	61536	0.50
1	Taliban	4294	0.04

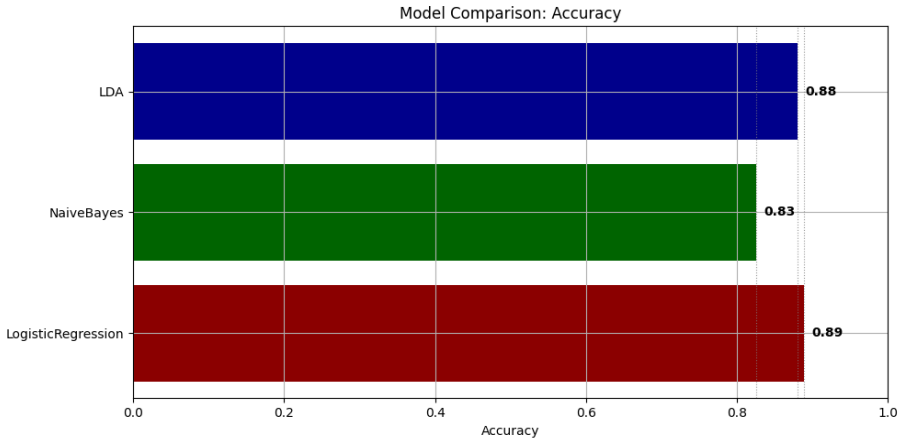

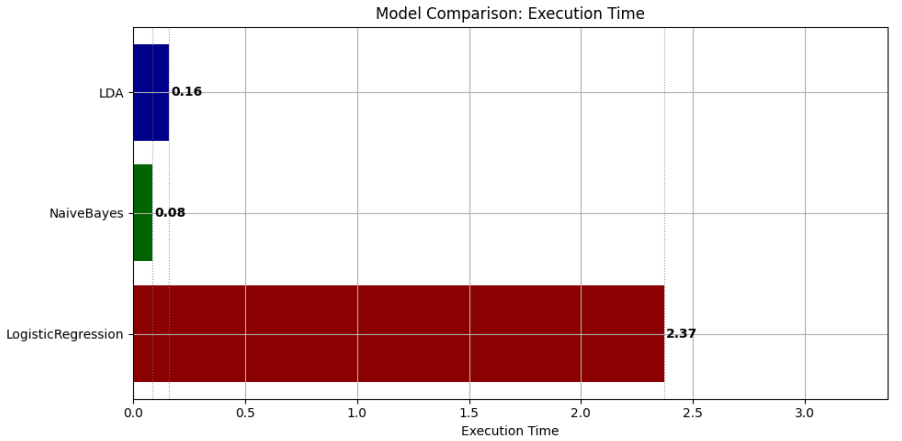

50% WE WILL FIND YOU!

La Linear Discriminant Analysis (LDA) rappresenta la soluzione più efficace ed equilibrata.

L'Accuratezza elevata, unita alla quasi totale assenza di falsi positivi e falsi negativi nella confusion matrix, la rende particolarmente affidabile per classificare correttamente i gruppi più attivi.

Identificare anche il 50% attacchi con gname sconosciuto, la LDA offre un supporto concreto per evidenziare pattern sospetti e migliorare le attività di monitoraggio.

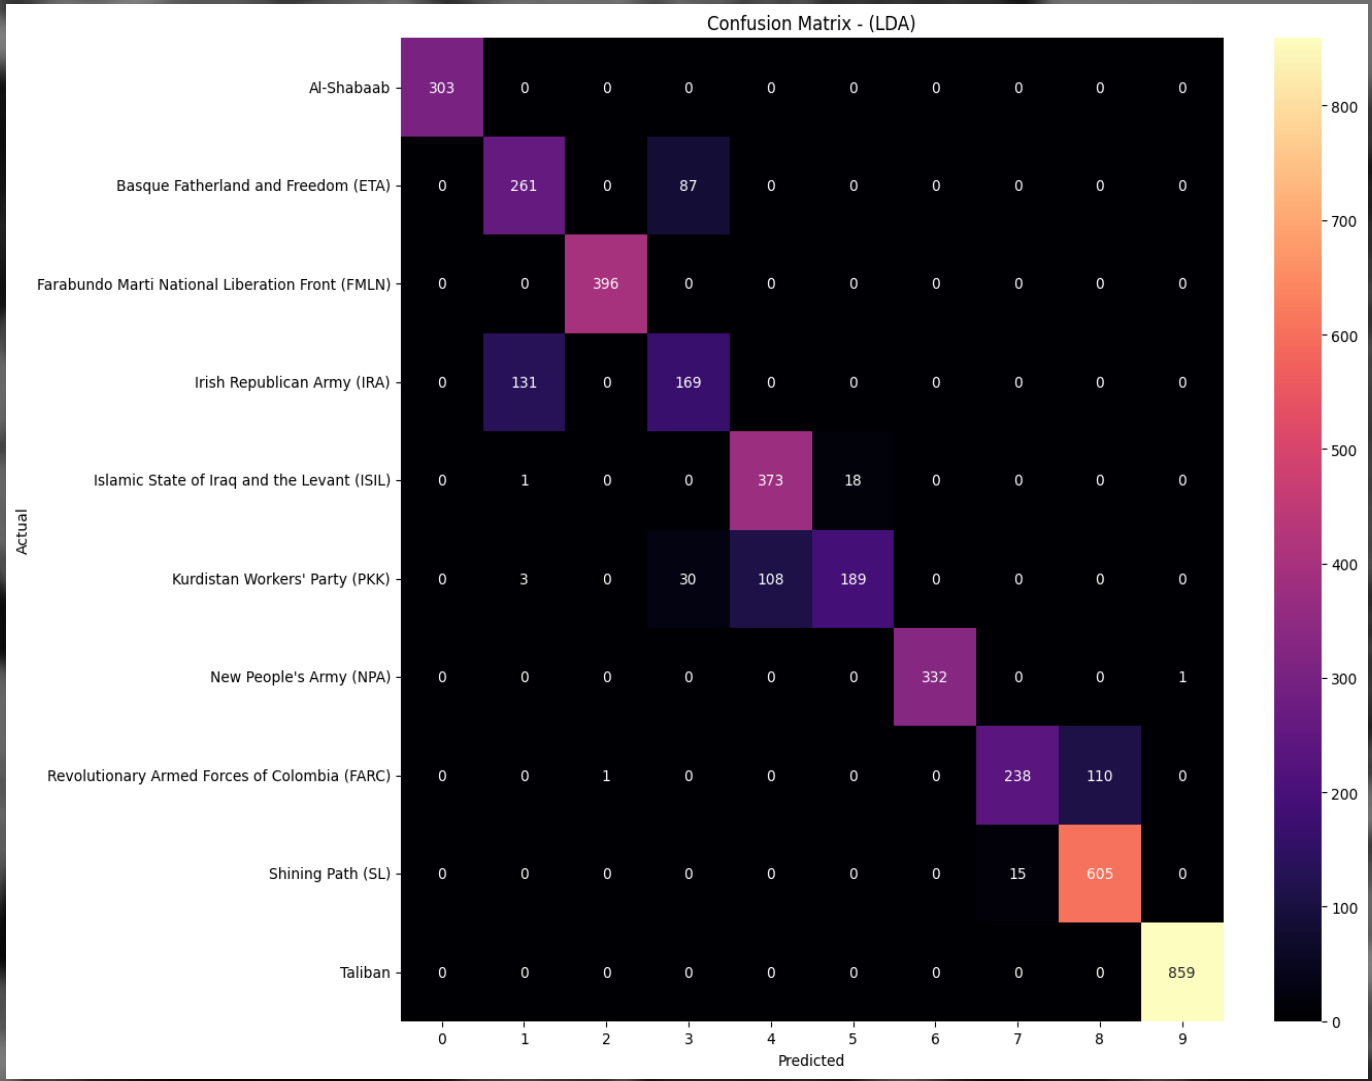

ANATOMIA DELLA PRESA DEGLI OSTAGGI

Strumenti: backward elimination, p-value, pseudo R-squared, intervalli di confidenza, logit, odds ratio

Questa analisi mostra che la presa di ostaggi è un fenomeno raro e molto strategico.
Gli attacchi con ostaggi tendono a essere meno letali, ma più controllati.
la durata, il numero di terroristi e il successo operativo sono fattori chiave.
Al contrario, un'elevata letalità o obiettivi istituzionali riducono la probabilità di ostaggi.

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	-5.6849	0.302	-18.852	0.000	-6.276	-5.094
C(targtype1_txt)[T.Educational Institution]	-0.0583	0.239	-0.244	0.808	-0.527	0.411
C(targtype1_txt)[T.Government (Diplomatic)]	-0.1835	0.228	-0.806	0.420	-0.630	0.263
C(targtype1_txt)[T.Government (General)]	-0.7514	0.164	-4.575	0.000	-1.073	-0.429
C(targtype1_txt)[T.Journalists & Media]	-0.4361	0.244	-1.785	0.074	-0.915	0.043
C(targtype1_txt)[T.Military]	-1.5589	0.251	-6.222	0.000	-2.050	-1.068
C(targtype1_txt)[T.Police]	-1.5974	0.221	-7.239	0.000	-2.030	-1.165
C(targtype1_txt)[T.Private Citizens & Property]	-0.0620	0.146	-0.425	0.671	-0.348	0.224
C(targtype1_txt)[T.Religious Figures/Institutions]	-1.0646	0.354	-3.004	0.003	-1.759	-0.370
C(targtype1_txt)[T.Terrorists/Non-State Militia]	-0.1604	0.366	-0.438	0.661	-0.878	0.557
C(targtype1_txt)[T.Transportation]	-1.1900	0.441	-2.701	0.007	-2.054	-0.326
C(targtype1_txt)[T.Unknown]	-0.2557	0.552	-0.463	0.643	-1.338	0.826
C(targtype1_txt)[T.Utilities]	-1.8770	0.853	-2.200	0.028	-3.549	-0.205
C(targtype1_txt)[T.Violent Political Party]	-1.5609	0.532	-2.934	0.003	-2.604	-0.518
C(weaptype1_txt)[T.Firearms]	2.4184	0.252	9.590	0.000	1.924	2.913
C(weaptype1_txt)[T.Incendiary]	-0.9043	0.543	-1.665	0.096	-1.969	0.160
C(weaptype1_txt)[T.Melee]	2.6277	0.323	8.136	0.000	1.995	3.261
C(weaptype1_txt)[T.Unknown]	4.2544	0.262	16.229	0.000	3.741	4.768
nkill	-0.9775	0.081	-12.051	0.000	-1.136	-0.819
success	0.9945	0.167	5.943	0.000	0.667	1.323
nperps	0.2168	0.017	13.090	0.000	0.184	0.249
extended	6.4106	0.342	18.731	0.000	5.740	7.081
nwound	-0.6570	0.086	-7.668	0.000	-0.825	-0.489

ZERO VITTIME: L'UMANITÀ NON SI TOCCA

Classifichiamo gli attacchi con vittime per poter intervenire tempestivamente.

Predittori: weaptype1_txt, attacktype1_txt, region_txt, targtype1_txt, nwound, success, suicide.

Strumenti: Preprocessing numerico e categorico, Suddivisione train/test set, Grid Search per C, Pipeline

Vogliamo un'alta recall (-FN), equilibrio e stabilità

Accuracy: 0.807480658167157

	precision	recall	f1-score	support
non letale	0.82	0.88	0.85	22311
letale	0.79	0.70	0.74	14397
accuracy			0.81	36708
macro avg	0.80	0.79	0.79	36708
weighted avg	0.81	0.81	0.81	36708

Accuracy: 0.5822436526097853

	precision	recall	f1-score	support
non letale	0.91	0.35	0.50	22311
letale	0.48	0.95	0.64	14397
accuracy			0.58	36708
macro avg	0.70	0.65	0.57	36708
weighted avg	0.74	0.58	0.56	36708

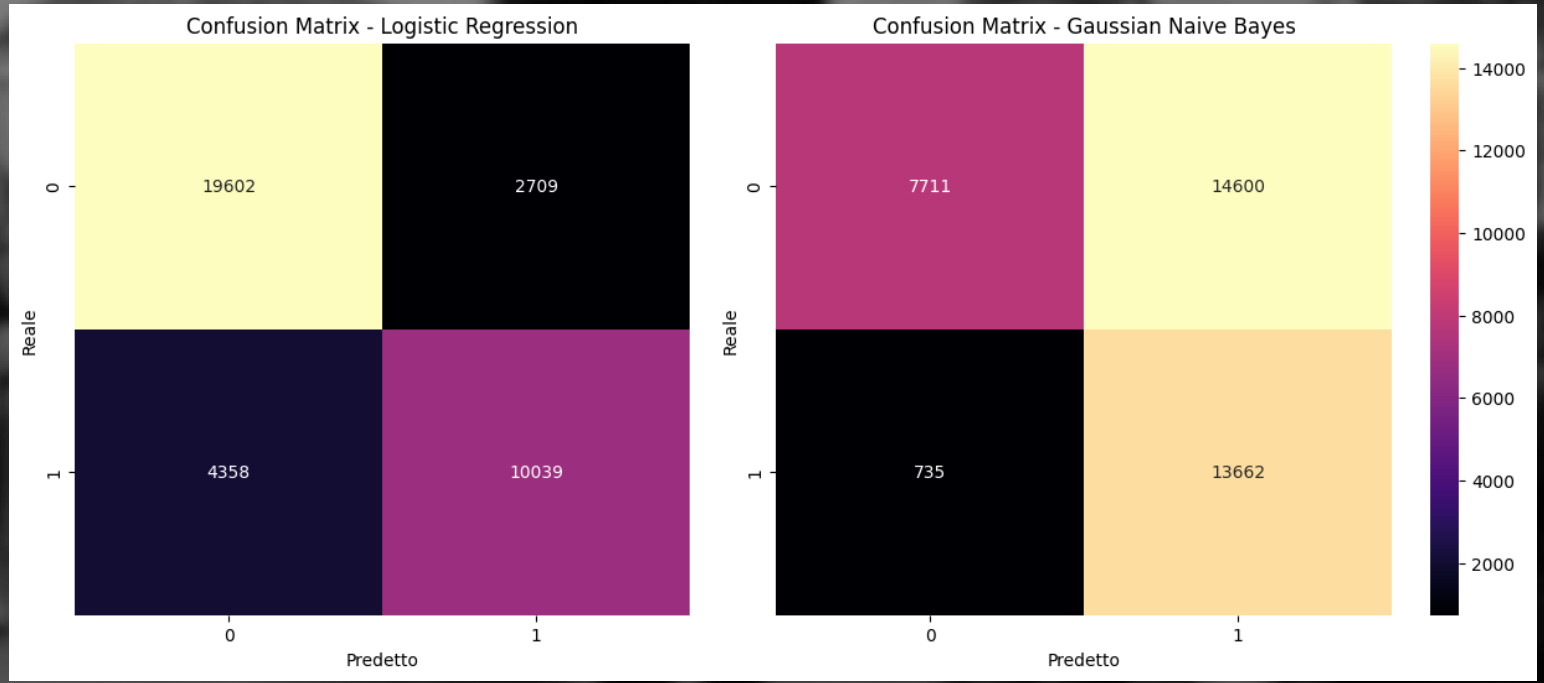

ZERO VITTIME: L'UMANITÀ NON SI TOCCA

Dalla Regressione Logistica:

Buon equilibrio tra recall (0.70) e precision (0.79).
In oltre è molto affidabile

Dalla Gaussian BN:

Con un recall del 95% ma una precision del 48% si forma un tradeoff sfavorevole, si creerebbero falsi allarmi su attacchi non letali.

Accuracy: 0.807480658167157

	precision	recall	f1-score	support
non letale	0.82	0.88	0.85	22311
letale	0.79	0.70	0.74	14397
accuracy			0.81	36708
macro avg	0.80	0.79	0.79	36708
weighted avg	0.81	0.81	0.81	36708

Accuracy: 0.5822436526097853

	precision	recall	f1-score	support
non letale	0.91	0.35	0.50	22311
letale	0.48	0.95	0.64	14397
accuracy			0.58	36708
macro avg	0.70	0.65	0.57	36708
weighted avg	0.74	0.58	0.56	36708

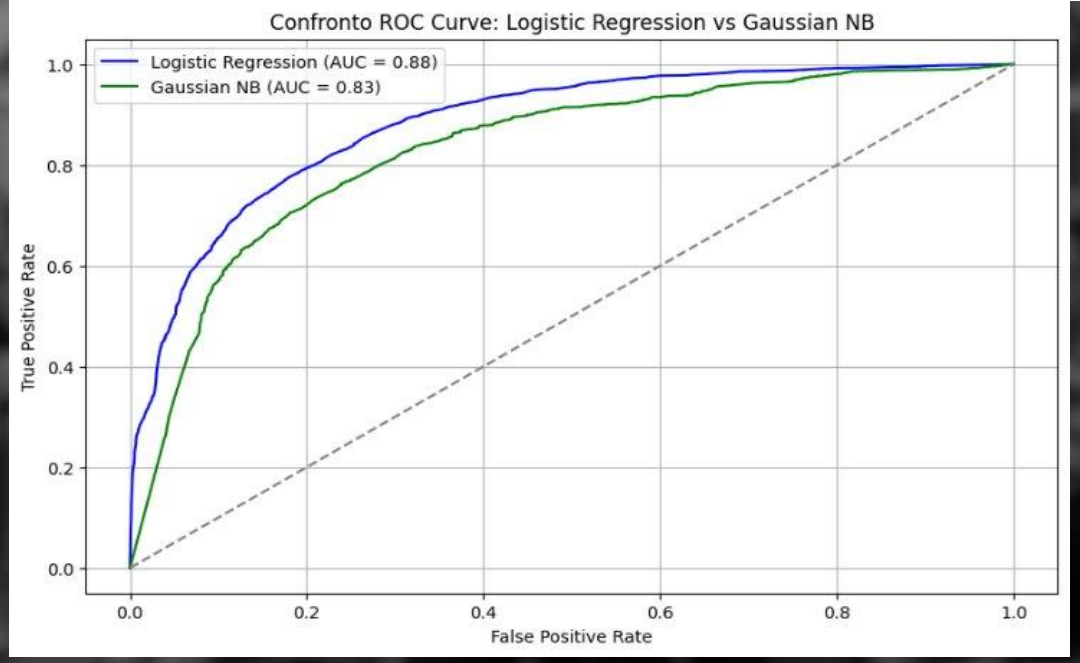

Dalla curva ROC:

Scegliamo il modello di Regressione Lineare. Riduciamo lo stesso i falsi negativi ed evitiamo falsi allarmi

3 TIPOLOGIE DI ATTACCO?

Una struttura complessa si annida negli attacchi terroristici.
Prendendo le 3 componenti principali ergo l'84% della varianza dei dati, il clustering individua tre tipologie di attacchi.

- Attacchi a bassa intensità o azioni dimostrative (rosso);
- Assalti armati intermedi (blu);
- Attacchi suicidi ad alta letalità (giallo);

cluster	nkill	nwound	nperps	suicide
0	0.613217	0.000000	2.634180	0.002397
1	0.518725	1.592231	2.453328	0.000225
2	1.576173	0.951406	1.308175	0.966589

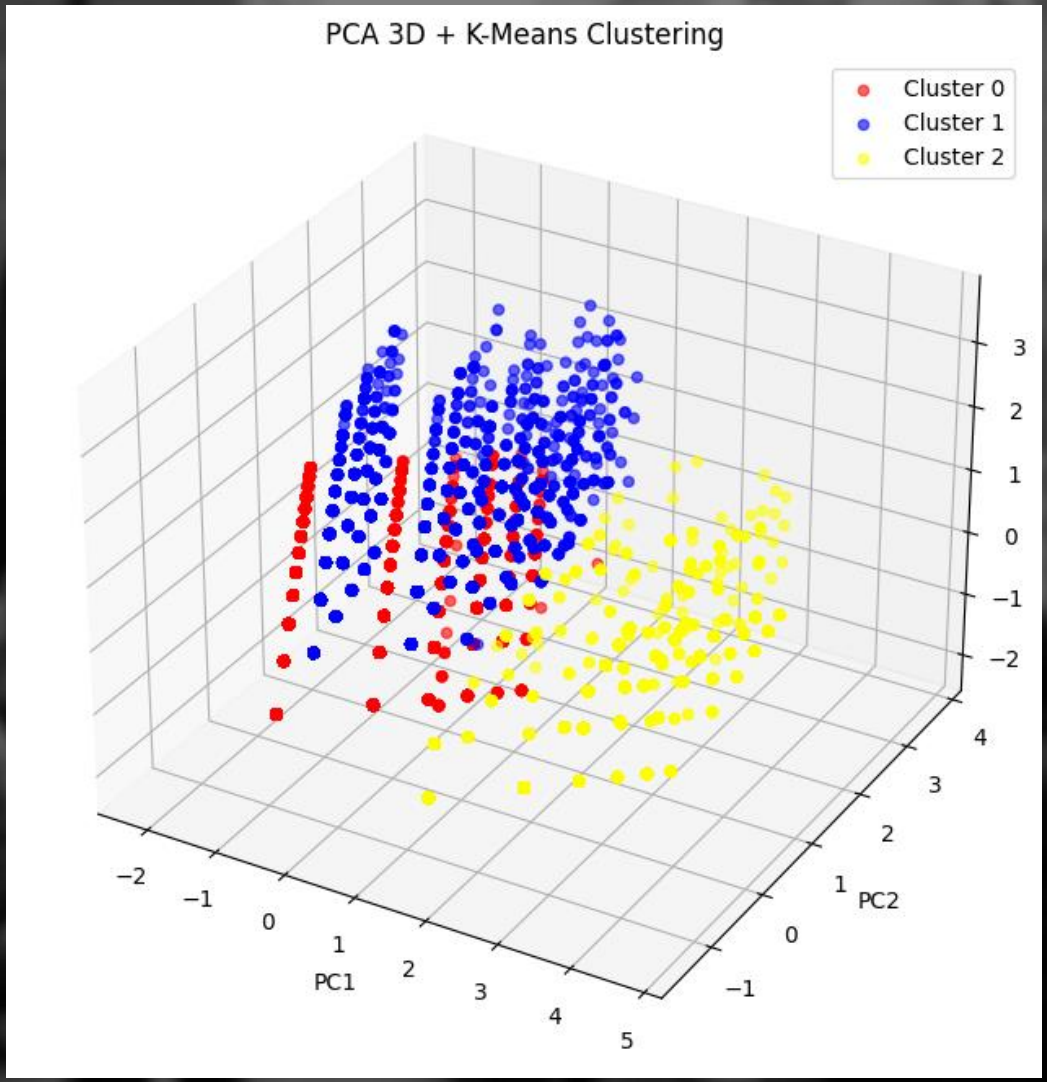

CONCLUSIONI…

CHI?/QUANTO?
DOVE?
PERCHÉ?
QUANDO?
COME?

GRAZIE

DATA SLAYER:

- VINCENZO PIO FALSAPERLA
- FLAVIO MICCICHÉ
- SANTO LO BIANCO